МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение
высшего образования «Самарский национальный исследовательский
университет имени академика С.П. Королева (Самарский университет)»

Институт информатики, математики и электроники

Факультет информатики

Кафедра программных систем

ОТЧЕТ

к лабораторной работе по дисциплине

«Нейронные сети глубокого обучения»

Студент Е. Г. Плешаков

Студент О.В. Ширяева

Преподаватель А. Н. Жданова

Самара 2021

СОДЕРЖАНИЕ

Постановка задачи

Цель лабораторной работы: реализовать нейронную сеть для классификации изображений.

Классификация (рубрикация) изображений представляет собой отнесение изображения к одной из нескольких категорий (рубрик) на основании его содержания. В одной из своих многочисленных постановок задача распознавания образов трактуется как отнесение предъявленного объекта по его формальному описанию к одному из заданных классов. Важно, что классы (категории, рубрики) в задаче классификации являются пересекающимися подмножествами, это значит, что изображение может быть отнесено к нескольким категориям одновременно.

– имеется множество категорий (классов, рубрик): $C = \{c_1,...c_{|C|}\}$;

– имеется множество изображений: $D = \{d_1,...d_{|D|}\}$;

– существует неизвестная целевая функция: $\Phi : C \times D \to \{0,1\}$;

– имеется некоторая начальная коллекция размеченных изображений $R \subset C \times D$, для которых известны значения Φ. Её делят на «обучающую» и «тестировочную» части. Первая используется для обучения классификатора, вторая – для проверки качества его работы.

– необходимо создать классификатор Φ', максимально близкий к Φ, который бы выдавал степень подобия $\Phi' : C \times D \to \{0,1\}$.

1 Описание архитектуры сети, метода обучения

Для решения поставленной задачи была построена свёрточная (convolutional) нейронная сеть, которая была обучена на нескольких тысячах изображений кошек и собак, чтобы затем предсказывать, кто изображен на картинке – кошка или собака.

Данные для датасета взяты с Kaggle: https://www.kaggle.com/tongpython/cat-and-dog. При работе над кодом сети использован источник https://becominghuman.ai/building-an-image-classifier-using-deep-learning-in-python-totally-from-a-beginners-perspective-be8dbaf22dd8

Для создания CNN (свёрточной нейронной сети) была использована библиотека глубокого обучения Keras с бэкендом на TensorlFlow на языке Python. Процесс построения CNN включает четыре основных этапа:

Шаг 1: Свертка (Convolution).

Шаг 2: Объединение (Pooling).

Шаг 3: Сглаживание (Flattening).

Шаг 4: Полное соединение (Full connection)

В качестве модели сети была выбрана последовательная (sequential) модель из keras.models. Существует два основных способа инициализации нейронной сети: последовательностью слоев или графом.

На первом шаге была использована двумерная свертка (Conv2D из keras.layers), поскольку распознаваемые изображениями представляют собой в основном двухмерные массивы. Трехмерные свёрточные слои могут использоваться, например, при работе с видео, где третьим измерением будет время.

Для второго шага – операции объединения – использована MaxPooling2D из keras.layers. MaxPooling помогает выбрать пиксель максимального значения из соответствующей интересующей области.

Для третьего шага – сглаживания – использован Flatten из keras.layers. Сглаживание – это процесс преобразования всех результирующих двумерных массивов в один длинный непрерывный линейный вектор.

Для выполнения полного подключения нейронной сети на 4 шаге был использован Dense из keras.layers.

Ниже приведён исходный код создания CNN.

```
from keras.layers import Conv2D
from keras.layers import Dense
from keras.layers import Flatten
from keras.layers import MaxPooling2D
from keras.models import Sequential
from tensorflow import keras

model = Sequential()
model.add(Conv2D(32, (3, 3), input_shape=(64, 64, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Conv2D(32, (3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Flatten())
model.add(Dense(units=64, activation='relu'))
model.add(Dense(units=1, activation='sigmoid'))
model.compile(optimizer='adam', loss='binary_crossentropy',
metrics=['accuracy'])

from keras.preprocessing.image import ImageDataGenerator

train_datagen = ImageDataGenerator(rescale=1. / 255,
                                   shear_range=0.2,
                                   zoom_range=0.2,
                                   horizontal_flip=True)
test_datagen = ImageDataGenerator(rescale=1. / 255)

batch_size = 32

training_set = train_datagen.flow_from_directory('dataset/training_set',
                                                 target_size=(64, 64),
                                                 batch_size=batch_size,
                                                 class_mode='binary')
test_set = test_datagen.flow_from_directory('dataset/test_set',
                                            target_size=(63, 64),
                                            batch_size=batch_size,
                                            class_mode='binary')

import os

cp_callback = keras.callbacks.ModelCheckpoint(filepath=os.curdir,
                                              save_weights_only=True,
                                              verbose=1)

model.fit(training_set,
          steps_per_epoch=8000 // batch_size,
          epochs=25,
          validation_data=test_set,
          validation_steps=2000 // batch_size,
          callbacks=[cp_callback])

model.save("keras_cnn")
print("Model saved")
```

Разберем приведенный выше код. Сначала создаётся объект, который уже имеет представление о том, какой будет данная нейронная сеть

(последовательная), затем был добавлен свёрточный слой с помощью функции «Conv2D». Функция Conv2D принимает 4 параметра, первый – это количество фильтров, т.е. 32 здесь, второй аргумент – это форма, которую будет иметь каждый фильтр, то есть здесь 3x3, третий – это форма ввода и тип изображения (RGB или черно-белое) каждого изображения. Таким образом, входное изображение, которое будет принимать наша CNN, имеет разрешение 64x64, а код «3» означает RGB. Четвертый параметр – это функция активации, которая будет использована, здесь «relu» означает функцию выпрямителя (rectified linear unit).

Далее нужно выполнить операцию объединения на результирующих картах характеристик, которые мы получаем после выполнения операции свёртки на изображении. Основная цель операции объединения – максимально уменьшить размер изображений, т.е. уменьшить общее количество узлов для следующих слоев.

Для начала нужно добавить слой объединения к объекту-классификатору. Взяв матрицу 2x2, с минимальной потерей пикселей можно получить точную область, в которой находится объект. Так, сложность модели уменьшается без понижения ее производительности.

Далее необходимо преобразовать все объединённые изображения в непрерывный вектор с помощью сглаживания. По сути, это операция преобразования двумерного массива, то есть объединённых пикселей изображения, в одномерный вектор.

Теперь нужно создать полностью связанный слой и к этому слою подключить набор узлов, которые мы получили после этапа выравнивания. Эти узлы будут действовать как входной слой для этих полностью связанных слоев. Поскольку этот слой будет находиться между входным и выходным слоями, можно назвать его скрытым слоем.

Dense – это функция для добавления полностью связанного слоя, «единицы» – это то место, где мы определяем количество узлов, которые должны присутствовать в этом скрытом слое, значение этих единиц всегда

будет между количеством входных и выходных узлов, но оптимальное количество узлов может быть достигнуто только экспериментальным путем. Чаще всего используют степень двойки и активационную функцию relu.

В конце необходимо инициализировать выходной слой, который должен содержать только один узел, поскольку это двоичная классификация. Этот единственный узел даст бинарный вывод: либо Cat, либо Dog. Для активации последнего слоя использована функция сигмоида. Для компиляции выбран алгоритм стохастического градиентного спуска («adam»), функция потерь («binary_crossectropy»), метрика эффективности («accuracy»).

Для подготовки тренировочного датасета использована библиотека keras.preprocessing, предлагающая различные типы операций, такие как переворачивание, вращение, размытие и т. д. Изображения в датасете структурированы по папкам и помечены как кошки или собаки. Параметром «steps_per_epoch» задаётся количество обучающих изображений в каждой эпохе. Эпоха – это один шаг в обучении нейронной сети; в нашем случае тренировочный процесс состоит из 25 эпох.

Для прогнозирования результатов обученной сетью используется метод «predict()», в который передаётся своё изображение. Поскольку прогноз будет в двоичной форме, результатом будет либо 1, либо 0, что будет представлять собаку или кошку соответственно.

```
plt.figure(figsize=(6, 6))
for index, row in sample_test.iterrows():
    filename = row['filename']
    img = load_img("dataset/control_set/" + filename, target_size=(200, 200))
    test_image = image.load_img("dataset/control_set/" + filename,
target_size=(200, 200))
    test_image = image.img_to_array(test_image)
    test_image = np.expand_dims(test_image, axis=0)
    result = model.predict(test_image)
    if result[0][0] == 1:
        prediction = 'dog'
    else:
        prediction = 'cat'
    category = prediction
    axes = plt.subplot(6, 3, index + 1)
    plt.imshow(img)
    plt.xlabel(format(category))
    axes.set_yticks([])
    axes.set_xticks([])
plt.tight_layout()
plt.show()
```

2 Вычислительные эксперименты

Для вычислительных экспериментов использовались 6 различных конфигураций сети. Зависимость точности сети, функции потерь и времени обучения от конфигураций сети представлена в таблице 1.

Таблица 1 – Зависимость показателей сети, от её конфигурации

Количество скрытых свёрточных слоёв	Количество нейронов в основных слоях		обучение		тестирование		время обучения, мин
	1 скрытый	2 скрытый	потери	точность	потери	точность	
0	128	0	0,2973	0,8724	0,6663	0,7792	52
1	128	0	0,1537	0,9388	0,6341	0,8160	64
2	128	0	0,2045	0,9152	0,3971	0,8503	70
0	256	32	0,2693	0,8931	0,7514	0,7525	55
1	256	32	0,1771	0,9275	0,5922	0,8090	66
2	256	32	0,1710	0,9308	0,4926	0,8362	72

На рисунках 1-3 представлены графики зависимости времени обучения, точности и функции потерь от конфигурации сети.

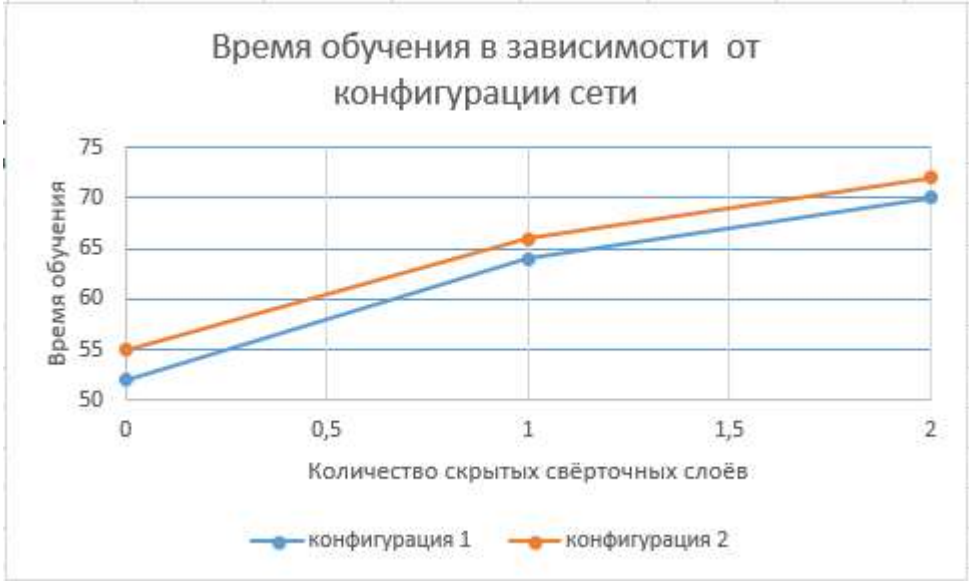

Рисунок 1 – Зависимость времени обучения от конфигурации основных слоёв сети

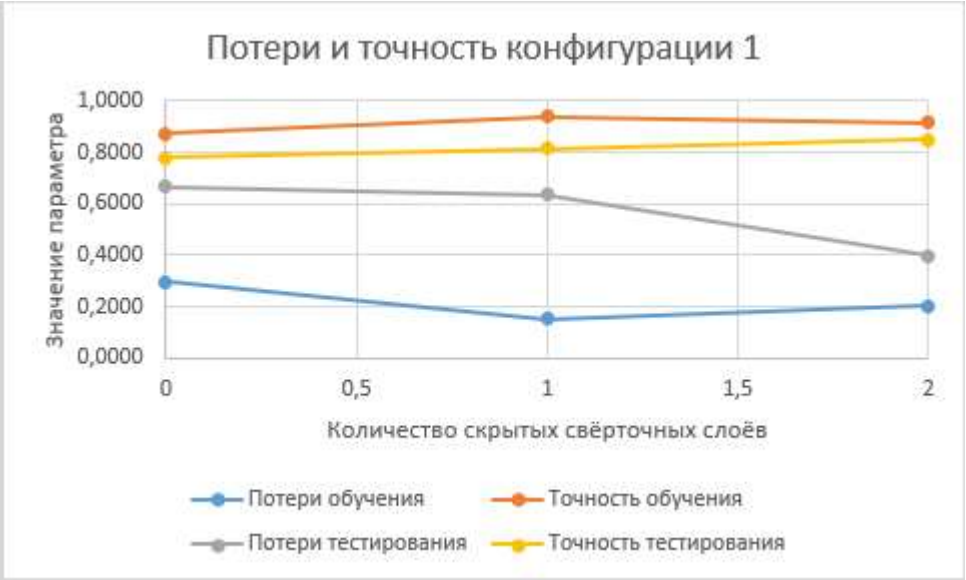

Рисунок 2 – Зависимость результатов обучения сети от количества свёрточных слоёв сети при первой конфигурации основных слоёв

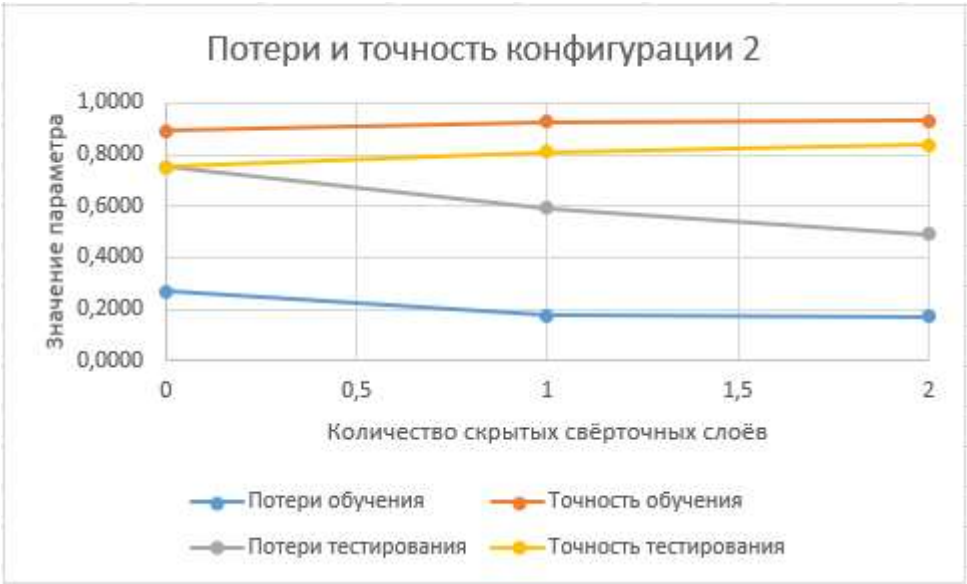

Рисунок 3 – Зависимость результатов обучения сети от количества свёрточных слоёв сети при второй конфигурации основных слоёв

3 Результат работы программы на своих данных

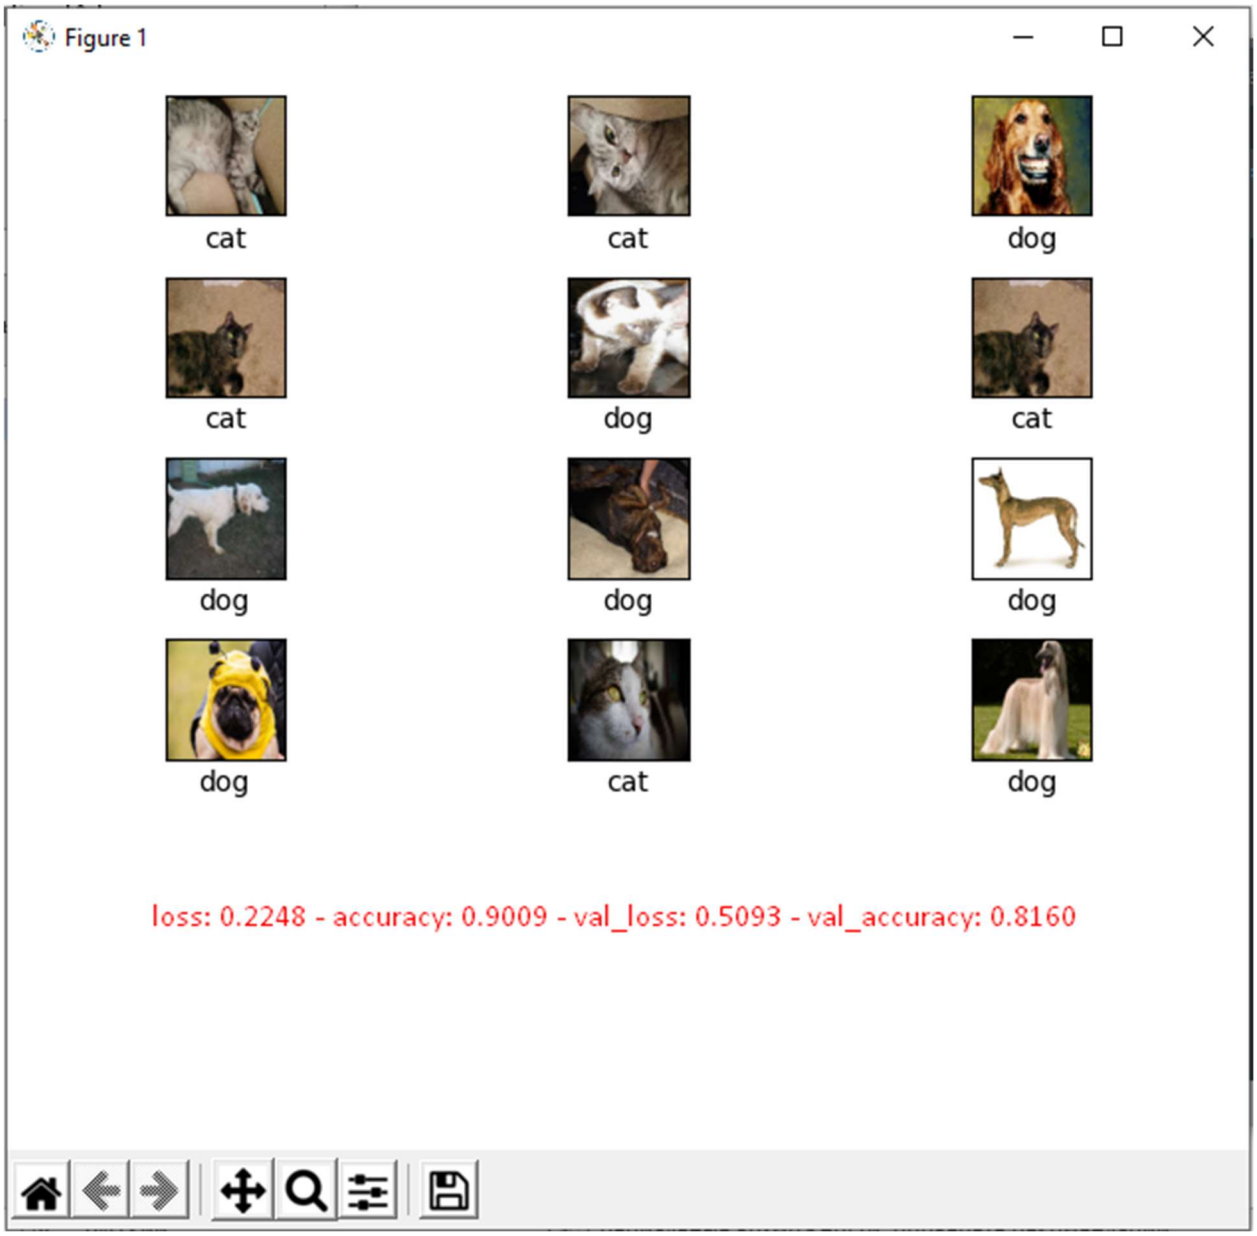

4 Вывод

В результате вычислительных экспериментов было обнаружено что точность сети растёт при увеличении количества свёрточных слоёв, однако это приводит к увеличению времени обучения. А вот дополнительные основные слои, хотя и увеличивают время обучения, на точность особо не влияют.

Приложение А

Код программы

Файл create_cnn.py

```
# Importing the Keras libraries and packages
from keras.layers import Conv2D
from keras.layers import Dense
from keras.layers import Flatten
from keras.layers import MaxPooling2D
from keras.models import Sequential
from tensorflow import keras

# Initialising the CNN
model = Sequential()
# Step 1 - Convolution
model.add(Conv2D(32,    (3,    3),    input_shape=(128,    128,    3),
activation='relu'))
# Step 2 - Pooling
model.add(MaxPooling2D(pool_size=(2, 2)))
# Adding a second convolutional layer
# model.add(Conv2D(32, (3, 3), activation='relu'))
# model.add(MaxPooling2D(pool_size=(2, 2)))
# Step 3 - Flattening
model.add(Flatten())
# Step 4 - Full connection
# model.add(Dense(units=256, activation='relu'))
model.add(Dense(units=64, activation='relu'))
model.add(Dense(units=1, activation='sigmoid'))
# Compiling the CNN
model.compile(optimizer='adam',              loss='binary_crossentropy',
metrics=['accuracy'])
# Part 2 - Fitting the CNN to the images
from keras.preprocessing.image import ImageDataGenerator

train_datagen = ImageDataGenerator(rescale=1. / 255,
                                   shear_range=0.2,
                                   zoom_range=0.2,
                                   horizontal_flip=True)
test_datagen = ImageDataGenerator(rescale=1. / 255)

batch_size = 32
```

```
training_set = train_datagen.flow_from_directory('dataset/training_set',
                                                 target_size=(128, 128),
                                                 batch_size=batch_size,
                                                 class_mode='binary')
test_set = test_datagen.flow_from_directory('dataset/test_set',
                                            target_size=(128, 128),
                                            batch_size=batch_size,
                                            class_mode='binary')

import os

cp_callback = keras.callbacks.ModelCheckpoint(filepath=os.curdir,
                                              save_weights_only=True,
                                              verbose=1)

model.fit(training_set,
          steps_per_epoch=8000 // batch_size,
          epochs=25,
          validation_data=test_set,
          validation_steps=2000 // batch_size,
          callbacks=[cp_callback])

model.save("keras_cnn")
print("Model saved")
```

Файл create_cnn.py

```
import os
import matplotlib.pyplot as plt
import matplotlib
import numpy as np
import pandas as pd
import tensorflow as tf
from keras.preprocessing import image
from keras.preprocessing.image import ImageDataGenerator, load_img

model = tf.keras.models.load_model("keras_cnn")
print("Model loaded")

train_datagen = ImageDataGenerator(rescale=1. / 255,
                                   shear_range=0.2,
                                   zoom_range=0.2,
                                   horizontal_flip=True)
```

```
test_datagen = ImageDataGenerator(rescale=1. / 255)
training_set = train_datagen.flow_from_directory('dataset/training_set',
                                                 target_size=(128, 128),
                                                 batch_size=32,
                                                 class_mode='binary')
test_set = test_datagen.flow_from_directory('dataset/test_set',
                                            target_size=(128, 128),
                                            batch_size=32,
                                            class_mode='binary')

test_filenames = os.listdir("dataset/control_set")
test_df = pd.DataFrame({
    'filename': test_filenames
})
nb_samples = test_df.shape[0]

sample_test = test_df.head(18)
sample_test.head()

plt.figure(figsize=(6, 6))
for index, row in sample_test.iterrows():
    filename = row['filename']
    img = load_img("dataset/control_set/" + filename, target_size=(128,
128))
    test_image = image.load_img("dataset/control_set/" + filename,
target_size=(128, 128))
    test_image = image.img_to_array(test_image)
    test_image = np.expand_dims(test_image, axis=0)
    result = model.predict(test_image)
    if result[0][0] == 1:
        prediction = 'dog'
    else:
        prediction = 'cat'
    category = prediction
    axes = plt.subplot(6, 4, index + 1)
    plt.imshow(img)
    plt.xlabel(format(category))
    axes.set_yticks([])
    axes.set_xticks([])
plt.tight_layout()
plt.show()
```